

Análisis Multivariante

Selección eficiente de técnicas de análisis multivariante

Índice

Esquema	3
Ideas clave	4
10.1. Introducción y objetivos	4
10.2. Según el tipo de variables	5
10.3. Según los resultados	7
10.4. Cuaderno de ejercicios	13
10.5. Referencias bibliográficas	16
A fondo	18
Test	19

SELECCIÓN EFICIENTE DE TÉCNICAS DE ANÁLISIS MULTIVARIANTE

¿QUÉ ES LO PRIMERO QUE SE HACE?

SE RECOGEN LOS DATOS

1. Seleccionando bien la muestra

2. Sabiendo las variables que se quieren estudiar

¿Y POSTERIORMENTE?

SE TRATA LA BASE DE DATOS

Para que cumplan ciertos requisitos estadísticos básicos

FINALMENTE ...

Para seleccionar la técnica a utilizar y obtener resultados y conclusiones interesantes se debe tener en cuenta:

- Si lo que se quiere es considerar las variables o las observaciones.
- El tipo de variables que se tienen.
- Los resultados que se quieren obtener o la técnica que mejores resultados da.

Esquema

10.1. Introducción y objetivos

En la vida real, nos encontramos frente a una base de datos donde la única actividad que se ha realizado es **recoger información de una serie de observaciones** a partir de ciertas variables.

Posteriormente, esta base de datos es tratada para que cumpla ciertos requisitos estadísticos básicos según el análisis previo de los datos.

Finalmente, para poder sacar resultados y **conclusiones interesantes** de estos datos y poder extrapolar esta información a toda la población, se debe aplicar una **técnica de análisis multivariante**. Sin embargo, esta técnica debe ser elegida a conciencia y no por el azar.

Para seleccionar la **técnica adecuada** al estudio que se quiere llevar a cabo, se deben tener en cuenta varios puntos:

- ▶ Si lo que se quiere es considerar las variables o las observaciones.
- ▶ El tipo de variables que se tienen.
- ▶ Los resultados que se quieren obtener o la técnica que mejores resultados da.

Por todo ello, en este tema se persiguen ciertos objetivos con el fin de que, al acabar la asignatura, los alumnos sepan defenderse en el ámbito donde se tiene un gran número de datos y una gran cantidad de variables.

El principal objetivo que se pretende conseguir es **seleccionar la técnica de análisis multivariante más eficiente** para los datos de los que se parte y correcta para el estudio que se quiera realizar.

10.2. Según el tipo de variables

Para ayudar a familiarizarse con las técnicas y saber aplicarlas a los datos de los que se parten, tenemos una primera clasificación. Veamos las preguntas:

- ▶ ¿Nuestra investigación responde a un problema de dependencia entre variables o de interdependencia entre ellas?
- ▶ ¿Cómo están medidas las variables implicadas, en escalas métricas o no métricas?
- ▶ Si estamos ante un problema de dependencia, ¿cuántas relaciones se plantean entre las variables dependientes e interdependientes? ¿Cuántas variables dependientes existen?

La **respuesta** a estas tres preguntas nos guía al **tipo de técnica de análisis multivariante** que debemos utilizar.

Veamos cómo se clasifican las técnicas estudiadas en esta asignatura según la respuesta a estas preguntas:

- ▶ Si la respuesta a la primera pregunta es que las variables son de **interdependencia**, es decir, todas las variables entran en el estudio de manera simultánea, se pueden usar las técnicas de análisis factorial, análisis de componentes principales, análisis de correspondencias y análisis conglomerados.

Sin embargo, si la respuesta es **dependencia**, entonces las técnicas más utilizadas son análisis de correlación canónica, regresión múltiple, análisis discriminante y MANOVA.

- Si lo que se conoce es el **número y cómo están medidas las variables**, se pueden utilizar según:

Variables implicadas medidas en:	Técnica
Escala métrica	► Análisis factorial ► Análisis de componentes principales
Escala no métrica	Análisis de correspondencias simples y múltiples
Escala métrica o no métrica	Análisis de conglomerados

Tabla 1. Existe interdependencia entre las variables. Fuente: elaboración propia.

Variables dependientes	Variables independientes	Técnica
1 variable cuantitativa	1 o n variables cuantitativas	Regresión múltiple
1 variable cualitativa	n variables cuantitativas	Análisis discriminante
p variables cuantitativas	p variables cuantitativas	Correlación canónica
p variables cuantitativas	1 o n variables cualitativas	MANOVA

Tabla 2. Existe dependencia entre las variables. Fuente: adaptado de Álvarez et al., 2006.

Para aclarar la **clasificación según el tipo de variables**, a continuación se verán varios ejemplos.

Dependencia

Se tienen datos de veinte alumnos de primero de la ESO, a los cuales se les han mirado las variables peso y altura.

Se puede ver que la variable peso, que es la variable dependiente, puede ser explicada por la variable independiente altura. Por tanto, este es un caso de dependencia en el que se pueden aplicar las técnicas análisis de correlación canónica, regresión múltiple, análisis discriminante y MANOVA.

La segunda cuestión es observar el número y tipo de medida de las variables. Se observa que hay una única variable dependiente, que es el peso, y está medida en escala métrica. Además, la variable independiente es una y es

cuantitativa. En consecuencia, en este caso, la técnica adecuada para aplicar a nuestros datos es la regresión múltiple (en este ejemplo, sería regresión simple por tener una única variable independiente).

Interdependencia

Se tienen datos de cien flores a las cuales se les han mirado las variables largo de sépalo, ancho de sépalo, largo de pétalo y ancho de pétalo.

Se puede ver que las cuatro variables son interdependientes. Por ello, las técnicas que pueden aplicarse son análisis factorial, análisis de componentes principales, análisis de correspondencias y análisis conglomerados.

Al ser todas las variables de tipo cuantitativo, se pueden utilizar de las cuatro técnicas anteriores todas menos el análisis de correspondencias.

10.3. Según los resultados

En este apartado se verán varios casos de aplicar las técnicas de análisis multivariante.

En un primer caso, se debe tener en cuenta **lo que se quiere estudiar**. Si son las **variables**, se deben aplicar distintas técnicas a las que se aplicarían si se quisieran estudiar los **individuos**.

Para **examinar las variables** se aplicarán técnicas como análisis factorial, análisis de componentes principales, análisis de correspondencias simples y múltiples, y análisis de correlaciones canónicas. El análisis factorial creará una combinación lineal de las variables, a la que se asigna el nombre de **factor**; en el análisis de componentes principales, esta combinación recibe el nombre de **componentes principales**; en el análisis de correspondencias, se llama **proyecciones**; y en el análisis de correlaciones canónicas, **funciones canónicas**.

El **objetivo** principal de estas técnicas es **reducir el número de variables** y obtener una simplificación de estas. Sin embargo, cada una de ellas tiene diferentes procedimientos y subsana diferentes supuestos básicos. Además, como se ha visto en el apartado anterior, **cada una es específica para un tipo de variables**. Por tanto, estos dos apartados se consideran por separado, pero, a la hora de aplicar una técnica, se deben tener en cuenta ambos.

Las técnicas que nos permiten estudiar las variables tienen diferencias entre ellas. Entre el análisis factorial y el análisis de componentes principales, las diferencias y semejanzas son:

Análisis factorial	Análisis de componentes principales
Explica correlaciones.	Explica variabilidad.
Trata de explicar las variables observadas en función de unos cuantos factores hipotéticos.	Proyecta las observaciones en un espacio de dimensión reducida con pérdida de información mínima.
Los factores son incorrelados solo dentro del espacio de los factores comunes.	Las componentes principales son incorreladas incondicionalmente.
Hay varios procedimientos de estimación. Hay varias soluciones.	Un único procedimiento de estimación. La solución es única.
Añadir un nuevo factor puede cambiar los anteriores.	Añadir una nueva componente principal no cambia a las anteriores.
Algunas soluciones son invariantes con respecto a los cambios de escala.	La solución cambia con los cambios de escala.
En algunos modelos es difícil estimar las communalidades.	No hay que estimar communalidades.
En algunos modelos complejos los cálculos son problemáticos.	Los cálculos son bastante simples.

Tabla 3. Diferencias y semejanzas entre el análisis factorial y el de componentes principales.
Fuente: elaboración propia.

Las principales **similitudes y disimilitudes** entre el análisis factorial y el de correspondencias son:

Análisis factorial	Análisis de correspondencias
Analiza las relaciones que hay entre las variables.	Analiza las relaciones que hay entre las variables y, además, indica cómo está estructurada esta asociación, describiendo «proximidades» que nos permiten, a su vez, identificar «categorías causa de asociación».
Busca resumir la información aportada por variables cuantitativas.	Busca resumir la información aportada por variables cualitativas.
Los resultados se representan gráficamente sobre ejes de coordenadas, lo que aporta una mejor interpretación de los resultados.	
Pese a que el análisis de correspondencias guarde ciertas similitudes con el análisis factorial, al cambiar el nivel de medida no tiene sentido iniciar nuestro análisis con la matriz de correlaciones.	
Al reducir las variables, se crean factores.	Al reducir las variables, se crean dimensiones.

Tabla 4. Similitudes y disimilitudes entre el análisis factorial y el de correspondencias.
Fuente: adaptado de Rodríguez y Catalá, 2001.

Respecto al análisis factorial y el de correlaciones canónicas, se puede observar:

Análisis factorial	Análisis de correlaciones canónicas
La interpretación de los valores teóricos puede ser fácil, ya que estos tienen ayudas para la interpretación, como puede ser la rotación de los valores teóricos, como se vio en el análisis factorial.	La interpretación de los valores teóricos canónicos puede ser difícil, ya que estos se calculan para maximizar la relación y no existen ayudas para la interpretación.
Los factores explican la máxima varianza.	Los pares de valores teóricos explican la mayor intercorrelación posible entre dos conjuntos de variables.
La obtención de sucesivos valores teóricos canónicos es similar al empleado en el análisis factorial sin rotación.	
Se asemejan en la creación de compuestos de variables.	
Las variables canónicas y los factores se ordenan de mayor a menor según el porcentaje de varianza o intercorrelación.	

Tabla 5. Similitudes y disimilitudes entre el análisis factorial y el de correlaciones canónicas.

Fuente: adaptado de Badii et al., 2007.

Para clarificar las **principales diferencias** entre el análisis de componentes principales y el análisis de correspondencias simples, se pone a continuación la siguiente imagen:




Figura 1. Disimilitudes entre el análisis de componentes principales y el de correspondencias.
Fuente: 3datos, 2011.

Para establecer la comparación entre el análisis de componentes principales y el de correlaciones canónicas, se crea la siguiente tabla:

Análisis de componentes principales	Análisis de correlaciones canónicas
No es favorable aplicarla cuando la matriz de correlaciones no es factorizable.	Es favorable aplicarla cuando la matriz de correlaciones no es factorizable.
Tratamiento de una matriz de datos continuos.	Tratamiento de dos tablas de datos.

Tabla 6. Disimilitudes entre el análisis de componentes principales y el de correlaciones canónicas.
Fuente: elaboración propia.

La comparación entre el análisis de correspondencias y correlaciones canónicas es:

Análisis de correspondencias	Análisis de correlaciones canónicas
Requieren más datos y son más difíciles de aplicar.	Requieren menos datos y son más fáciles de aplicar.
Los resultados dan una visión mucho menos global.	Los resultados dan una visión mucho más global.

Tabla 7. Disimilitudes entre el análisis de componentes principales y el de correlaciones canónicas.
Fuente: elaboración propia.

Todas estas diferencias y similitudes de las técnicas nos servirán para su **aplicación según los datos y resultados** que se quieran obtener.

Para examinar los individuos u observaciones dadas en los datos, se debe aplicar el análisis de conglomerados o el análisis factorial jerárquico. En nuestro caso, aplicaremos normalmente el **análisis de conglomerados**, ya que ha sido el que hemos estudiado a fondo y, además, tiene varios métodos para estudiar dependiendo de sus características.

En este vídeo se explica cómo aplicar estas dos técnicas de análisis multivariante en una base de datos.

 [Accede al vídeo](#)

En este vídeo se explica qué técnica de análisis multivariante aplicar según tres criterios.

 [Accede al vídeo](#)

En este vídeo se hablará desde el punto de vista de un profesional en análisis multivariante sobre la manera de elegir la técnica adecuada a lo que se pide en cada momento.



Accede al vídeo

10.4. Cuaderno de ejercicios

1. Teniendo una base de datos con las siguientes variables:

Variable	Tipo de variable
Estado de las habitaciones	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}
Comida	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}
Atención del personal no sanitario	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}
Atención del personal auxiliar sanitario	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}
Atención del personal de enfermería	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}
Atención del personal médico	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}
Información recibida	Cuantitativa {1-Totalmente en desacuerdo, 2-En desacuerdo, 3-Ni de acuerdo ni en desacuerdo, 4-De acuerdo, 5-Totalmente de acuerdo}

Tabla 8. Variables para ejercicio. Fuente: adaptado de Llopis Pérez, 2014.

¿Qué técnica se aplica si se quieren agrupar las variables?

- Solución: análisis factorial o análisis de componentes principales.

2. Se tiene una base de datos sobre vinos con las siguientes variables:

Variable	Tipo de variable
Año	Cualitativa {1986, 1987}
Denominación	Cualitativa {Ribera, Toro}
Grado alcohólico	Cuantitativa {10'80,14}
Acidez volátil	Cuantitativa {0'30,1'60}
Acidez total	Cuantitativa {3'80,7'70}
Acidez fija	Cuantitativa {3'30,6'80}
Fenoles totales	Cuantitativa {925,3152}
Índice de color	Cuantitativa {1'95,7'91}
Tono de color	Cuantitativa {0'46,0'93}
Índice de ionización	Cuantitativa {12'90,38'10}

Tabla 9. Variables medidas en 45 vinos. Fuente: elaboración propia.

¿Qué técnica se aplica si se quieren agrupar los individuos?

- Solución: análisis de conglomerados.

3. Se miden las siguientes variables fisiológicas (tres primeras) y relacionadas con el deporte (tres últimas) a veinte individuos de un gimnasio:

Variable	Tipo de variable
Peso (en libras)	Cuantitativa {138-247}
Altura (en pulgadas)	Cuantitativa {31-46}
Pulso (pulsaciones por minuto en reposo)	Cuantitativa {46-74}
Salto	Cuantitativa {1-17}
Sentadillas	Cuantitativa {50-251}
Flexiones	Cuantitativa {25-250}

Tabla 10. Variables fisiológicas para ejercicio. Fuente: adaptado de Ayala, 2020.

Tres de las variables son dependientes y tres independientes. ¿Qué técnica de análisis multivariante se debe emplear para estudiarlas?

- Solución: análisis de correlaciones canónicas.

4. Se tiene la siguiente base de datos:

Accede a la base de datos «Conjunto de datos flor iris» a través de la siguiente página web: https://es.wikipedia.org/wiki/Conjunto_de_datos_flor_iris

Realizar un análisis multivariante aplicando alguna de las técnicas, con el fin de agrupar las flores según la especie.

- Solución: se explica en el vídeo.



Accede al vídeo

5. Se tiene una base de datos con las siguientes variables:

Variable	Tipo de variable
Sexo	Cualitativa
Religión	Cualitativa
Nacionalidad	Cualitativa
Nivel de estudios	Cualitativa
Guerras	Cualitativa
Terremotos	Cualitativa
Climatologías adversas	Cualitativa
Huelgas	Cualitativa
Cambios políticos	Cualitativa

Tabla 11. Variables para ejercicio. Fuente: Parra, 2019.

¿Qué técnica se aplica si quiere estudiar la variable del país creando unas variables nuevas?

- Solución: análisis de correspondencias múltiples.

10.5. Referencias bibliográficas

3datos. (2011). *Estudios de Mercado: el Análisis Factorial de Componentes Principales “vs” el Análisis de Correspondencias*. <http://3datos.es/content/uploads/2011/04/AF-de-CP-vs-AC.pdf>

Álvarez, M., Caballero, A. y Pérez, G. (julio de 2006). *análisis multivariante: clasificación, organización y validación de resultados*. Fourth LACCEI International Latin American and Caribbean Conference for Engineering and Technology

(LACCET'2006). Mayagüez, Puerto Rico.

<https://www.researchgate.net/publication/228368538>

Ayala, J. (17 de febrero de 2020). *Minería de Datos*.

<https://rpubs.com/JairoAyala/575486>

Badii, M. H., Castillo, J., Cortez, K., Wong, A. y Villalpando, P. (2007). Análisis de correlación canónica (ACC) e investigación científica. *InnOvaciOnes de NegOciOs* 4(2), 405-422. <http://eprints.uanl.mx/12486/1/A9%20%281%29.pdf>

Caballero, A. y Pérez Lechuga, G. (2006). *Análisis multivariante: clasificación, organización y validación de resultados*.

<https://www.researchgate.net/publication/228368538>

Conjunto de datos flor iris. (14 de julio de 2021). En *Wikipedia*.

https://es.wikipedia.org/wiki/Conjunto_de_datos_flor_iris

Llopis Pérez, J. (12 de enero de 2014). Explotación de una base de datos 1: Base de datos. *La estadística: una orquesta hecha instrumento*.

<https://illopisperez.com/2014/01/12/explotacion-de-una-base-de-datos-1-base-de-datos/>

Parra, F. (25 de enero de 2019). *Estadística y Machine Learning con R* (capítulo 5).

<https://bookdown.org/content/2274/modelos-con-variables-cualitativas.html>

Peña, D. (2002). *Análisis de datos multivariantes*. McGraw Hill.

Rodríguez, M. J. y Catalá, R. M. (2001). *Estadística Informática: casos y ejemplos con el SPSS* (pp. 43-56). Publicaciones de la Universidad de Alicante.

<https://rua.ua.es/dspace/bitstream/10045/12073/1/Capitulo3.pdf>

Guía de Análisis Multivariante

Ciencia y Técnica Administrativa. (junio de 2005). *Guía de Análisis Multivariante*.
http://www.cyta.com.ar/biblioteca/bddoc/bdlibros/guia_multivariante/guia_multivariante.htm

Página web interesante, principalmente, para saber diferenciar las escalas de medida y para conocer la clasificación de las técnicas de análisis multivariante.

Introducción a los métodos multivariantes

León Darío Bello Parías. (23 de febrero de 2023). *Introducción métodos multivariantes.avi* [Vídeo]. YouTube. <https://www.youtube.com/watch?v=9DMz-489uEk>

Este recurso es útil para saber usar las técnicas de análisis multivariantes según el tipo de variables.

Análisis estadístico multivariado aplicado

Karl Härdle, W. y Simar, L. (2015). *Applied Multivariate Statistical Analysis*. Springer.

Libro para repasar todas las técnicas de análisis multivariante estudiadas a lo largo de la asignatura y para ampliar conocimiento sobre nuevas técnicas.

1. Una vez se han recogidos los datos, se debe:
 - A. Sacar resultados.
 - B. Obtener conclusiones.
 - C. Tratar los datos para que cumplan algunos supuestos básicos.
 - D. Extrapolar los resultados a una población.

2. ¿Qué técnica se utiliza si existe interdependencia entre las variables?
 - A. Análisis factorial.
 - B. Análisis de componentes principales.
 - C. Análisis de correspondencias y análisis conglomerados.
 - D. Todas las anteriores son ciertas.

3. ¿Qué técnica se utiliza si existe dependencia entre las variables?
 - A. Análisis de correlación canónica.
 - B. Regresión múltiple.
 - C. Análisis discriminante y MANOVA.
 - D. Todas las anteriores son ciertas.

4. ¿Qué técnica se utiliza si todas las variables son cualitativas?
 - A. Análisis de conglomerados.
 - B. Análisis de componentes principales.
 - C. Análisis de correspondencias simples y múltiples.
 - D. A y C son correctas.

5. ¿Qué técnica se utiliza si la variable dependiente es cualitativa y las demás son cuantitativas?
- A. Regresión múltiple.
 - B. Análisis discriminante.
 - C. Correlación canónica.
 - D. MANOVA.
6. Un tipo de clasificación de las técnicas es según:
- A. Si lo que se quiere estudiar es los individuos o las observaciones.
 - B. Si lo que se quiere estudiar es las variables o los campos.
 - C. Si lo que se quiere estudiar es los individuos o las variables.
 - D. Todas son ciertas.
7. Indica la frase correcta:
- A. El análisis factorial explica la variabilidad.
 - B. El análisis de componentes principales explica correlaciones.
 - C. El análisis factorial explica correlaciones.
 - D. Todas son ciertas.
8. Indica la frase correcta:
- A. El análisis factorial busca resumir la información aportada por variables cualitativas.
 - B. El análisis de correspondencias busca resumir la información aportada por variables cualitativas.
 - C. El análisis factorial busca resumir la información aportada por variables cuantitativas.
 - D. B y C son ciertas.

9. Indica la frase correcta:

- A. En el análisis de correlación canónica, los pares de valores teóricos explican la mayor intercorrelación posible entre dos conjuntos de variables.
- B. En el análisis factorial, los pares de valores teóricos explican la mayor intercorrelación posible entre dos conjuntos de variables.
- C. En el análisis de correlación canónica, los factores explican la máxima varianza.
- D. Todas son falsas.

10. Indica la frase correcta:

- A. La matriz de datos en el análisis de componentes principales es similar a una tabla de contingencia.
- B. La matriz de datos en el análisis de correspondencias simple es similar a una tabla de contingencia.
- C. La matriz de datos en el análisis de correspondencias simple es por filas los individuos y por columnas las variables.
- D. La matriz de datos en el análisis de componentes principales es por filas las variables y por columnas los individuos.